

Processamento de Imagens e Redes Neurais Convolucionais Aplicadas à Histologia Colorretal

1. Introdução

O câncer colorretal é um dos tipos de tumor com maior incidência globalmente. O diagnóstico e a análise do microambiente tumoral dependem fortemente da avaliação de lâminas histológicas (tecidos biológicos tingidos e observados ao microscópio) por patologistas. A automação dessa análise por meio da Inteligência Artificial pode auxiliar patologistas, reduzindo o tempo de processamento e aumentando a consistência das avaliações.

Dessa forma, este trabalho tem como objetivo desenvolver, treinar e comparar dois modelos de Redes Neurais Convolucionais (CNNs) capazes de classificar 8 diferentes tipos de texturas e tecidos presentes em amostras de histologia colorretal.

2. Metodologia e Base de Dados

A base de dados utilizada foi a 'colorectal_histology', extraída da biblioteca TensorFlow Datasets. Ela é composta por 5.000 imagens RGB de dimensões 150x150 pixels, divididas uniformemente em 8 classes biológicas: epitélio tumoral, estroma simples, estroma complexo, células imunológicas, resíduos/muco, glândulas mucosas, tecido adiposo e fundo (sem tecido).

A base foi dividida em 70% para treino e 30% para teste/validação, permitindo avaliar o desempenho dos modelos em dados não utilizados durante o treinamento e os valores dos pixels foram normalizados para uma escala entre de 0 a 1, a fim de acelerar a convergência das redes.

Foram implementadas duas abordagens distintas:

2.1. Modelo Base (Transfer Learning - MobileNetV2): utilizou-se a base convolucional do MobileNetV2, uma arquitetura de alta eficiência pré-treinada com os pesos do conjunto ImageNet. Os pesos pré-treinados foram mantidos congelados, sendo utilizados apenas para a extração de características das imagens e uma nova forma de classificação foi adicionada, composta por uma camada *GlobalAveragePooling2D* e uma camada *Dense* final de 8 neurônios com ativação *Softmax*.

2.2. Arquitetura da CNN personalizada: para estabelecer um termo de comparação com a MobileNetV2, foi desenhada uma arquitetura profunda com 9 camadas, pensada especificamente para extrair padrões de texturas celulares sem colapsar em *overfitting*. A arquitetura divide-se nas seguintes fases:


- Fase de Extração de Características (Blocos Convolucionais):
 - Bloco 1 (32 filtros, 3x3) + MaxPooling (2x2): O primeiro bloco convolucional é responsável pela extração de características visuais básicas presentes nas imagens.

- Bloco 2 (64 filtros, 3x3) + MaxPooling (2x2): O segundo bloco amplia a capacidade de representação do modelo, permitindo a identificação de padrões visuais mais complexos.
- Bloco 3 (128 filtros, 3x3) + MaxPooling (2x2): O terceiro bloco busca capturar características de maior complexidade associadas às diferentes classes do conjunto de dados.
- Todas as camadas convolucionais utilizam a função de ativação ReLU (*Rectified Linear Unit*), essencial para introduzir não-linearidade no modelo e mitigar o problema da dissipação do gradiente. As camadas de MaxPooling2D operam a redução da dimensionalidade espacial, garantindo que o modelo aprenda a reconhecer a célula independentemente da sua posição exata na imagem, além de reduzir o custo computacional.
- Fase de Transição e Classificação Final:
 - Flatten: Transforma os mapas de características tridimensionais (saídos do último MaxPooling) num vetor unidimensional contínuo.
 - Dense (512 neurónios, ReLU): Camada responsável por combinar as características extraídas anteriormente para realizar a classificação final.
 - Dropout (0.5): Como o conjunto de treino é relativamente pequeno (3.500 imagens), o modelo apresenta maior risco de overfitting devido ao tamanho reduzido da base de treinamento. Sendo assim, o Dropout desativa aleatoriamente 50% das conexões durante o treino. Essa estratégia reduz a dependência excessiva de neurónios específicos e melhora a capacidade de generalização do modelo.
 - Dense (8 neurónios, Softmax): A camada de saída que converte os sinais processados numa distribuição de probabilidades matemáticas para as 8 classes biológicas.

Ambos os modelos foram compilados utilizando o otimizador *Adam* e a função de perda *Sparse Categorical Crossentropy*, sendo treinados ao longo de 10 épocas.

3. Resultados e Discussão

3.1. Análise das Curvas de Aprendizado (Acurácia e Perda)




Fonte: A autora

Observando o gráfico de validação, o comportamento dos modelos foi notavelmente distinto:

- O modelo 'MobileNetV2' apresentou uma curva suave de aprendizado, atingindo estabilidade de acurácia em torno de 88% a partir da 7ª época. A queda progressiva da curva de *perda* demonstra que o modelo convergiu com sucesso. Por outro lado, a 'CNN Personalizada' apresentou maior variância e instabilidade, com picos e quedas na curva de *perda* (oscilando entre 0.6 e 1.0) e acurácia flutuante (entre 65% e 80%). Esse comportamento sugere que o treinamento da CNN personalizada foi mais sensível à quantidade de dados disponíveis quando comparado ao modelo baseado em transfer learning.

3.2. Matrizes de Confusão




Fonte: A autora


A matriz de confusão revela onde os modelos concentram os seus erros. O MobileNetV2 obteve uma diagonal principal com valores mais elevados, acertando com precisão as classes "Fundo" e "Adiposo" (tecidos de fácil diferenciação visual). As maiores confusões de ambos os modelos ocorreram entre "Estroma Simples", "Estroma Complexo" e "Resíduos".

Esse resultado pode ser explicado pela semelhança visual existente entre essas estruturas histológicas.

3.3. Interpretabilidade com Grad-CAM



Fonte: A autora



Fonte: A autora

Para garantir que a rede aprendeu os padrões biológicos e não ruídos periféricos da imagem, foi aplicado o algoritmo Grad-CAM (*Gradient-weighted Class Activation Mapping*). Os mapas térmicos revelaram que, nas classificações de "Glândulas", a rede (em vermelho, pois as cores quentes representam onde a rede neural focou para classificar a imagem) analisou os padrões circulares do tecido de maneira correta. No tecido "Adiposo", o foco contornou as membranas em formato de favo. Os mapas gerados pelo Grad-CAM sugerem que a CNN personalizada concentrou sua atenção em regiões biologicamente relevantes das imagens.

4. Conclusão

O projeto demonstrou o poder e as limitações das arquiteturas de Redes Neurais Convolucionais. O uso de Transfer Learning (MobileNetV2) apresentou desempenho superior ao da CNN desenvolvida neste trabalho para problemas de classificação histológica em bases limitadas. Simultaneamente, o desenvolvimento da CNN personalizada (com o seu aumento progressivo de filtros e aplicação de Dropout) permitiu

observar, na prática, conceitos importantes de visão computacional e aprendizado profundo, demonstrando a capacidade das CNNs de identificar padrões relevantes em imagens histológicas.

Por fim, apesar dos resultados positivos, o estudo apresenta limitações relacionadas ao tamanho da base de dados e ao número de épocas utilizadas no treinamento. Trabalhos futuros podem investigar técnicas de aumento de dados e ajuste de hiperparâmetros.